

Capitolo 5

Cappuccino ribelle

May 2026

1 Determinazione del numero di Risorse

la **configurazione** di un progetto di produzione deve determinare il **numero di risorse** necessarie a realizzare un dato processo, e la loro **organizzazione** per minimizzare le perdite di efficienza dovute all'articolazione del processo.

Guardando a una sola tecnologia in una sola fase del ciclo, il rendimento di questa tecnologia si può scrivere come:

$$\frac{Q_u}{Q} = \eta < 1 \text{ con } \eta = K_1 \cdot K_2 \cdot K_3 \cdot K_4$$

Dove:

- Q_u : potenzialità effettiva della risorsa
- Q : potenzialità nominale della risorsa
- K_1 : coefficiente di scarto: quanti scarti genera la lavorazione
- K_2 : coefficiente di disponibilità: per quanto tempo è richiesta la risorsa rispetto al totale della lavorazione
- K_3 : coefficiente di rendimento dell'operatore: rendimento dell'operatore, con considerazioni sulla sua formazione, ma anche pause e perdite di tempo altre
- K_4 : coefficiente di utilizzo: capacità dell'organizzazione di mettere in condizioni la macchina di funzionare

Questi coefficienti possono essere presi da dati storici, stimati, o ottenuti dal fornitore, e permettono di stimare la capacità produttiva da installare.

Nota la potenzialità produttiva da installare, si può calcolare il numero di tipo j per la lavorazione i-esima è:

$$M'_{ij} = \frac{Q_{ij}}{\frac{1}{T_{ij}} N_{ij}} \left[\frac{\frac{\text{pezzi}}{\text{anno}}}{\frac{\text{pezzi}}{\text{ora}} \frac{\text{ore}}{\text{anno}}} \right]$$

Espressione derivante dalla richiesta totale di lavorazione del prodotto i richiesta alla macchina j per un anno (Q_{ij}) da dividere per quanti pezzi può lavorare ciascuna macchina.

Prendendo questo valore, e sommando per tutti i prodotti che richiedono questa macchina, si calcola quante macchine di tipo j servono:

$$M_j = \left[\sum_{i=1}^m M'_{ij} \right]$$

E da qui è immediato definire il tasso di utilizzazione della risorsa (macchina) j come:

$$u_j = \frac{\sum_{i=1}^m M'_{ij}}{\left[\sum_{j=1}^m M_j \right]}$$

Che sarà minore o uguale 1: minore se magari ho 3 macchine, ma per esaudire la domanda me ne servirebbero 2.8, 1 in caso di saturazione perfetta delle macchine.

Osservando l'andamento per una sola macchina della potenzialità di utilizzazione al variare della quantità richiesta, si osserva un andamento a dente di sega, dovuto al fatto che, fino ai 40 prodotti/ora basta una macchina, ma quando diventano 50, la macchina scende da satura a $u = \frac{50}{80}$, quando diventano 90 si ha $u = \frac{90}{120}$. Il fatto che $\frac{90}{120} > \frac{50}{80}$ mostra il motivo per cui i denti si appiattiscono verso l'alto.




Figure 1: 1 macchina, 40 pezzi/ora

In caso di j macchine in serie, tutti con diversa potenzialità, si fa una media ponderata sul numero di macchine per ogni operazione, correggendola eventualmente con fattori economici (costo orario di tenere accesa la macchina...), per ottenere la relazione:

$$U = \frac{\sum_{j=1}^N u_j M_j}{\sum_{j=1}^N M_j}$$

E l'andamento sarà comunque a dente di sega, ma più irregolare di quello precedente: dato che si moltiplica ciascun andamento di macchina singola per

una costante (rapporto in numeri di macchine, costo orario) si sta facendo una combinazione lineare di andamenti a dente di sega, e ne risulta un dente di sega




Figure 2: Andamento per j macchine in serie

2 Bilanciamento delle linee di produmine

Il **bilanciamento** di un sistema produttivo consiste nella riduzione dei tempi di attività e della regolazione delle velocità tra le diverse operazioni, per avere un flusso di produzione organico e costante, sfruttando al massimo le risorse disponibili. La soluzione teoricamente ottimale è quella in cui tutte le stazioni operative lavorano al massimo, allo stesso ritmo, senza giacenze tra una stazione e l'altra; questo è impossibile, ma ci si deve tendere, massimizzando i coefficienti di utilizzo delle risorse, e mantenendo un ritmo costante.

Il bilanciamento deve partire da 4 fattori:

- L'output, che dipende dal mercato
- Vincoli di precedenza, tecnologici
- disponibilità delle risorse
- vincoli di disposizione delle risorse

In caso di **produzioni di massa di prodotti poco differenziati**, i ritmi sono scanditi dalle macchine, dunque l'operazione di bilanciamento si può fare a valle della progettazione. Questa può essere affrontata analiticamente.

Produzioni a gamma altamente differenziata invece richiedono un continuo bilanciamento, per rispondere alle richieste di specializzazione del cliente. Solitamente questa viene affrontata con metodologie empiriche o simulative.

Si parte dunque da un insieme non ordinato di elementi, e tramite l'aggregazione delle operazioni in stazioni di lavoro, la disposizione di un numero di magazzini di data entità, si arriva a un impianto organizzato, e dotato di cuscinetti per i sincronismi, di entità variabile.

2.1 Aggregazione delle operazioni in stazioni

Per eseguirla si parte da 2 dati:

- TCL : Tempo di Ciclo, il tempo impiegato da un prodotto ad attraversare una stazione
- TP_i : Tempo di esecuzione di ciascun elemento minimo di lavoro, vale a dire di ogni fase elementare di lavoro, non ulteriormente scomponibile.

Se Q^* è il lotto da produrre, e TP è data dalla somma dei tempi minimi di lavorazione $\sum_{i=1}^n TP_i$.

$$TCL = TP/Q^* = 1/P$$

Supponendo di avere un trasferimento in continua (stazioni disposte lungo un nastro trasportatore automatizzato).

$$TCL = \frac{DT}{v}$$

Il contenuto di lavoro totale rappresenta la somma di tutti gli i-esimi elementi di lavoro minimo, da ripartire tra le M stazioni.

Se ad una stazione sono attribuiti j elementi di lavoro, si può definire il TOP_j , il tempo di operazione della stazione, come:

$$TOP_j = \sum_{k=1}^{n_j} TP_k$$

Come il tempo che impiega ad eseguire tutti gli elementi di lavoro assegnatile; non coincide per forza col TCL, dato che un pezzo può anche dover essere spostato tra le parti di una stazione, oppure rimanere bloccato tra 2 macchine di una stazione per code. Si definisce dunque il tempo di inattività TI :

$$TI = TCL - TOP_j$$

La somma di tutti i tempi di inattività sulle j stazioni mi da il ritardo complessivo della linea: il balance delay:

$$BD = \sum_{j=1}^M TI_j = \sum_{j=1}^M (TCL - TOP_j)$$

Si può infine definire il coefficiente di inattività:

$$i = \frac{BD}{TCL}$$

2.1.1 Criterio di Salveson

Il modello di Salveson ipotizza l'assenza di un vincolo d'ordine, quindi spesso porta a risultati incongruenti. Matematicamente, si tratta di scegliere il massimo valore tra M' , M'' che minimizza il coefficiente di inattività. M' è il numero di stazioni che minimizzano di fatto BD:

$$i = \frac{BD}{TCL} = \frac{\sum_{j=1}^M (TCL - TOP_j)}{TCL} = \frac{M \cdot TCL - \sum_{j=1}^M TOP_j}{TCL} = M - \frac{\sum_{j=1}^M \sum_{k=1}^{n_j} TP_k}{TCL}$$

Dato che il rapporto alla fine di questa relazione è una costante, rimane da minimizzare M , che in questo caso consiste nel ricercare la partizione dei TP_i perché risultino tutti minori dei TCL , e perché la relazione di minimizzazione risulti effettivamente minima. Tuttavia, se esistessero alcuni elementi tali che:

$$TP_i > TCL/2$$

Questi elementi non potrebbero essere accorpati in una stazione, e richiedono ciascuno una propria stazione, portando a un numero M'' di stazioni. Dunque, il criterio si riduce a una scelta di:

$$M = MAX\{M', M''\}$$

2.1.2 Criterio di Elmaghraby

Lo strumento principe dei criteri che tengano conto delle precedenze è la **matrice delle precedenze P** , la quale ha valore:

$$P_{h,k} = \begin{cases} 1 & \text{se esiste un vincolo di precedenza tra h e k} \\ 0 & \text{altrimenti} \end{cases} \quad (1)$$

Quindi, se raccolgo in un vettore **TP** i tempi di esecuzione dei minimi di lavoro, posso calcolare:

$$(P + I_n)(TP) = KP$$

¹

E riordino il vettore $\overline{KP}$ in ordine decrescente di tempi, avrò ottenuto un vettore che, al primo posto, ha l'operazione che ne precede di più, quindi che va eseguita prima di tutte. A lei associo la prima stazione, $j=1$. Quindi calcolo il tempo residuo:

$$TR_j = TCL - TP_1$$

Inserisco l'operazione KP_2 nella stazione j -esima sse:

- Tutte le stazioni precedenti sono state svolte in stazioni $g \leq j$
- $TP_2 \leq TR_j$

¹L'aggiunta della matrice identità serve a tenere conto non solo del tempo delle operazioni seguenti, ma anche di quello proprio di ciascuna operazione

Nel caso una di queste non fosse soddisfatta, provo a capire se $KP_{3,4,\dots}$ rispettano i 2 criteri e possono essere inserite, nel rispetto dei vincoli tecnologici. Fatto ciò, se ho ancora lavorazioni da inserire, introduco una nuova stazione e ripeto il processo.

2.2 Giacenze interoperazionali

Sono necessarie al bilanciamento in quanto permettono:

- Lo sfruttamento delle potenzialità sprecate nei tempi morti; bilancio le diversità di ritmo.
- Disaccoppiamento temporaneo di una macchina in avaria dal resto, in caso di guasto; dispongo di una scorta di sicurezza.
- Tempi di lavoro più lunghe per le stazioni più lente, così da attenuarne l'effetto rallentante.

2.2.1 Numero dei magazzini intermedi

La determinazione del numero di magazzini intermedi pone a massimizzare il coefficiente di rendimento dell'impianto. La formulazione di Vladzyevsky prevede: La definizione di un coefficiente globale di inattività I , che prenda quello definito per la singola stazione:

$$i = \frac{BD}{TCL}$$

E lo espande per raccogliere anche le microfermate, o le avarie delle macchine. I viene definito in legame al rendimento di impianto.

$$\eta = \frac{1}{1 + I}$$

In una lina in cui non ci fossero magazzini, i ritardi accumulati su una linea si sommerebbero. Definendo I_j i ritardi accumulati nella singola stazione rapportati al TCL , e con $\bar{I}$ il coefficiente della linea senza magazzini -caso particolare di I -, si avrebbe:

$$\bar{I} = \sum_{j=1}^M I_j$$

Ma con un magazzino interposto, l'effetto del ritardo nella stazione 1 viene attenuato nelle sue ripercussione: questo viene dunque riscalato con δ **t.c.** $0 < \delta < 1$:

$$I = \delta_1 I_1 + I_2$$

Sotto l'ipotesi semplificativa che i magazzini siano dimensionati per mantenere δ costante, risulta immediato:

$$I = I_{MG} + \delta I_{MG-1} + \delta^2 I_{MG-2} + \dots + \delta^{MG-1} I_1$$

Dove l'aumento dell'esponente indica che l'effetto che arriva sulla stazione 3 dalla stazione 1 è attenuato dai magazzini a valle di 1 e 2, alla stazione 4 l'attuazione è dai magazzini 1, 2, 3...

Se i coefficienti di attività non attenuati di tutte le stazioni sono uguali ($\bar{I}_i = \frac{\bar{I}}{MG} = cost$), si può raccogliere a fattor comune:

$$I = \frac{\bar{I}}{MG}(1 + \delta + \delta^2 + \dots + \delta^{MG-1})$$

Che trascurando i termini di ordine superiore al primo diviene:

$$I = \frac{\bar{I}}{MG}(1 + \delta)$$

Che corretto per tenere conto delle perdite di tempo dei trasporti da e verso il magazzino fa ottenere infine:

$$I = \frac{\bar{I}}{MG}(1 + \delta) + IM(MG - 1)$$

Con una definizione finita di I in mano, si può tornare alla definizione data all'inizio di I per ottenere il **rendimento d'impianto in funzione di MG, numero di magazzini**:

$$\eta = \frac{1}{1 + \frac{\bar{I}}{MG}(1 + \delta) + IM(MG - 1)}$$

E non rimane che derivare e annullare, per massimizzare questa funzione e ottenere:

$$MG^* = \sqrt{\frac{\bar{I}}{IM}}(1 + \delta)$$

Si nota che all'aumentare di IM (e in un certo senso della distanza dei magazzini dalle stazioni) è saggio aggiungere più magazzini, per diminuire IM: al limite, si può avere un magazzino a valle di ogni stazione.

2.2.2 Entità delle scorte interoperazionali

Il WIP (Work In Process) è la quantità di materiale che è in attesa di subire le lavorazioni, ma è ancora nel processo.

Lo studio del WIP è centrale perché può modificare i tempi di attraversamento e garantire alimentazione costante alle macchine.


Si parte dal considerare una linea che opera con tempi di lavorazione costanti, e che sfrutta le risorse al massimo delle loro capacità. In questo caso si ha:

- Potenzialità uguale a quella del collo di bottiglia P_b
- Tempo a valore aggiunto uguale alla somma di tutte le lavorazioni $T_{OVA} = \sum_i TP_i$


Se e solo se il WIP è al suo valore critico: $WIP = WIP_c$.

L'andamento del WIP e del TA può essere visualizzato tramite il **diagramma del tempo di attraversamento**, in cui si rappresentano due *cumulate*, una del lavoro in ingresso, una del lavoro in uscita.

In questo diagramma il WIP si ottiene come la distanza verticale tra le cumulate, mentre il TA come la distanza orizzontale tra le stesse.



(a) Diagramma di attraversamento



(b) Potenzialità media

La potenzialità media è la pendenza della retta per gli estremi delle rispettive cumulate e l'origine degli assi.

Ancora, analizzando il diagramma di attraversamento, si può dedurre la capacità di una macchina o stazione di supportare un grado di lavoro, e individuare eventualmente avarie (come nel caso in basso a destra) o sottoalimentazioni (a sinistra). Il caso a destra mostra anche un sottoimpiego della stazione, che è quello che ha consentito un recupero del ritardo.




Figura 9 – Interpretazione del diagramma di attraversamento

2.2.3 Legge di Little e curve logistiche operative

Si precisa anzitutto che potenzialità e tempo di attraversamento non sono sempre semplicemente l'una l'inversa dell'altra.

Preso ad esempio una stazione con una macchina da 2 pezzi al minuto: in assenza di buffer (quindi WIP proprio di 2 pezzi che vengono lasciati in attesa) in effetti il TA è di 30 secondi a pezzo, ma presa una linea che invece abbia i buffer: Un pezzo in entrata deve aspettare 30" perché il pezzo in lavorazione al




Figure 4: Linea con buffer

momento della sua entrata venga lavorato, poi deve aspettare che il pezzo che era già a magazzino prima di lui venga lavorato, poi può entrare lui: il TA si è esteso quindi a $3 \cdot 30" = 90"$.

Per cercare di legare P, WIP e TA Little individua la legge:

$$WIP = P \cdot TA$$

La quale però non è esaustiva, una equazione per 3 incognite. Dunque, Hopp e Spearman individuano delle curve, approssimate (e approssimabili) a causa del difficile reperimento dei dati (tipo Wöhler), da utilizzare come supporto nella progettazione. Essi individuano 3 curve descrittive teoriche: una per il caso migliore, una per il caso peggiore, una per la massima casualità.

La caratteristica di queste curve è che operano tutte il CONWIP (a WIP costante): per ottenere questa condizione, ci si può immaginare di associare ad ogni item nel processo un cartellino all'inizio. A fine processo, questo cartellino viene staccato dal pezzo e riportato a inizio processo: solo pezzi con cartellino possono entrare nel processo, mantenendo il numero di parti nel processo uguale a quello dei cartellini, quindi costante.

Il Caso Migliore

- Linea perfettamente bilanciata
- Una macchina per stazione, 4 stazioni
- $Pb = 0.5 \frac{\text{pezzi}}{\text{ora}}$

Per ogni pezzo ho 4 stazioni, che ci lavorano 2 ore, quindi il T_{VA} è di 8 ore, il TA è 8 ore, e se il WIP è 1 la potenzialità produttiva è di 1 pezzo ogni 8 ore.

Provando ad aumentare il WIP si verifica quanto sotto:




Figure 5: Caso migliore con WIP crescente




Figura 15 – Leggi del caso migliore

Figure 6: Leggi del caso migliore

In breve, il TA rimane costante, quindi la legge di Little suggerisce che, se il WIP aumenta, aumenta anche la potenzialità produttiva, appunto perché il tempo di attraversamento quello è.

Ma se il WIP supera 4, all'inizio del processo si aggiungono 2 ore di attesa per ogni pezzo aggiunto, quindi comunque 1 pezzo per ogni 2 ore di TA aggiuntivo: si ha un plateau di P col WIP.

$$WIP_c = P_b \cdot T_{A_{min}} = P_b \cdot T_{VA}$$

Riassumendo in grafica:

Il plateau è causato dunque da un aumento lineare sia del TA all'aumentare del WIP

IlCaso peggiore

- ogni stazione prima lavora tutti i pezzi di un lotto, poi li manda
- i tempi di lavoro sono 4 ore per un pezzo, 0 per l'altro

In questo caso, ho comunque un $T_{VA} = 8h$, dato che in media un pezzo viene lavorato per 2 ore a stazione. Il tempo di attraversamento è però di 16h, che con un WIP di 2 indica: $P = \frac{2}{16} = \frac{1}{8}$

Se metto un WIP di 4 pezzi, cambia il tempo di attraversamento, dato che adesso ad ogni stazione ci si deve stare 8 ore, per 4 stazioni ho 32 ore, e la potenzialità rimane invariata. Graficamente:

Massima Casualità Si colloca tra i due estremi, entrambi irrealistici, e definisce il caso pratico peggiore che si possa ammettere.




Figura 17 – Leggi del caso peggiore

Figure 7: Leggi del caso peggiore

Supponiamo che i tempi di lavorazione delle macchine siano tutti uguali ma casuali secondo $e^{-\lambda t}$, e che il WIP possa essere distribuito altrettanto casualmente lungo tutte le stazioni della linea. Se il WIP è uguale a 3 per 4 stazioni, ad esempio, ho 20 combinazioni possibili.

In virtù dell'appartenenza dei tempi di lavorazione ad una esponenziale, la probabilità di complemento al tempo $t + dt$ di una lavorazione che in t è incompleta è:

$$P(t < \bar{t} < t + dt \mid \bar{t} > t) = \frac{P(t < \bar{t} < t + dt)}{P(\bar{t} > t)} = \frac{f(t)dt}{e^{-\lambda \cdot t}} = \frac{\lambda e^{-\lambda \cdot t} dt}{e^{-\lambda \cdot t}} = \lambda \cdot dt$$

Ancora, se prendi M stazioni, e ricordi TCL come il tempo impiegato da una lavorazione ad essere eseguita in una stazione:

$$T_{VA} = M \cdot TCL; P_b = \frac{1}{TCL}$$

Se WIP=w, e i pezzi sono distribuiti equamente sulla linea, un pezzo che arriva ha davanti a se $\frac{w-1}{M}$ pezzi, e deve dunque attendere $TCL \frac{w-1}{M}$.

Quindi, se TA_s è il tempo di attraversamento di una singola stazione:

$$TA_s = TCL + TCL \cdot \frac{w-1}{M}$$

↓

$$TA_{\max \text{ casualità}} = M \cdot TCL + TCL(w-1) = T_{VA} + \frac{w-1}{P_b}$$

↓

$$P_{\max \text{ casualità}} = \frac{w}{WIP_C + w - 1} P_b$$




Figure 8: Leggi di massima casualità




Figure 9: Impianto multmacchina sbilanciato

Individuate le curve di massima casualità, è importante individuare l'area positiva, come quella racchiusa tra il caso pratico peggiore e il caso pratico migliore, e accertarsi che l'impianto, che sia in progettazione o valutazione, operi in quell'area.

Impianto non bilanciato multmacchina Anche se le condizioni in cui opera un impianto non sono quelle descritte sopra, è comunque possibile costruire la curva analitica, per il paragone con quelle precedenti:

Il bilanciamento è imperfetto, e le stazioni non sono una per macchina, ma in ogni caso si può:

- Calcolare la P_b , dividendo volta per volta il numero di pezzi per il tempo di attraversamento di ciascuna macchina
- Calcolare la WIP_c come T_{VA} (direttamente dalla def, dato che il WIP critico corrisponde al tempo di attraversamento uguale al T_{VA})

La curva si può ricavare per vie analitiche, modellistiche o simulative. In questo caso si ottiene:

Incremento delle prestazioni L'incremento delle prestazioni può essere fatto sul collo di bottiglia: questo modifica sia le curve di Hopp e Spearman sia la curva operativa, perché aumenta la potenzialità globale d'impianto. Questo però costa, quindi si può scegliere di intervenire anche sulle stazioni che non siano a collo di bottiglia. In quel caso si diminuisce il WIP_c , il che è molto di aiuto per produzioni di volume minore.




Figure 10: Curva impianto multimacchina sbilanciato

2.2.4 Entità delle scorte interoperazionali

Prendendo il caso di due linee separate da un magazzino interoperazionale: Sia




Figure 11: Serie sezionata da un magazzino interoperazionale

$g(\tau)$ la densità di probabilità dei guasti di S1, e sia μ il suo valore atteso, che sappiamo coincidere al MTTF. All'aumentare dell'entità della scorta nel magazzino dei semilavorati, aumenta l'indipendenza di S1 da S2: si deve dunque ricercare la dimensione Q da attribuire a questo magazzino. Si stabiliscono $\frac{Q}{d}$ il tempo di esaurimento da parte di S2 della scorta ineroperazionale, e CUM il costo unitario di immagazzinamento.

Nel caso in cui il tempo di sosta di S1 supera il tempo di esaurimento scorte di S2, anche S2 si ferma, e se CA è il costo unitario di fermata di S2, non rimane che ricavare una funzione costo totale CT , e ottimizzare.

$$CA \cdot \int_{Q/d}^{\infty} \left(\tau - \frac{Q}{d} \right) g(\tau) d\tau$$

$$\Downarrow$$

$$CT = CUM \cdot Q + \frac{CA}{\mu} \cdot \int_{Q/d}^{\infty} \left(\tau - \frac{Q}{d} \right) g(\tau) d\tau$$

$\Downarrow$

$$\frac{dCT}{dQ} = 0 = CUM + \frac{CA}{\mu} \cdot \left(-\frac{1}{d} \right) \int_{Q/d}^{\infty} g(\tau) d\tau = CUM - \frac{CA}{\mu d} \cdot \left[1 - G\left(\frac{Q}{d} \right) \right]$$

Nota: dato che $g(\tau)$ è pur sempre una distribuzione di probabilità, il suo valore a infinito è 1: è normalizzata per definizione.

Per isolare Q, a questo punto, devo introdurre l'inversa di G, la funzione $\bar{G}$ tale che:

$$\bar{G}(G(\tau)) = \tau$$

E infine:

$$Q = d \cdot \left[\bar{G} \left(1 - \frac{CUM \cdot d \cdot \mu}{CA} \right) \right]$$

valida solo se:

$$\frac{CUM \cdot d \cdot \mu}{CA} < 1$$